Можно ли автоматизировать признаки для рекомендаций?

Временная грамматика агрегатов и отбор признаков против сильного CatBoost на KION.

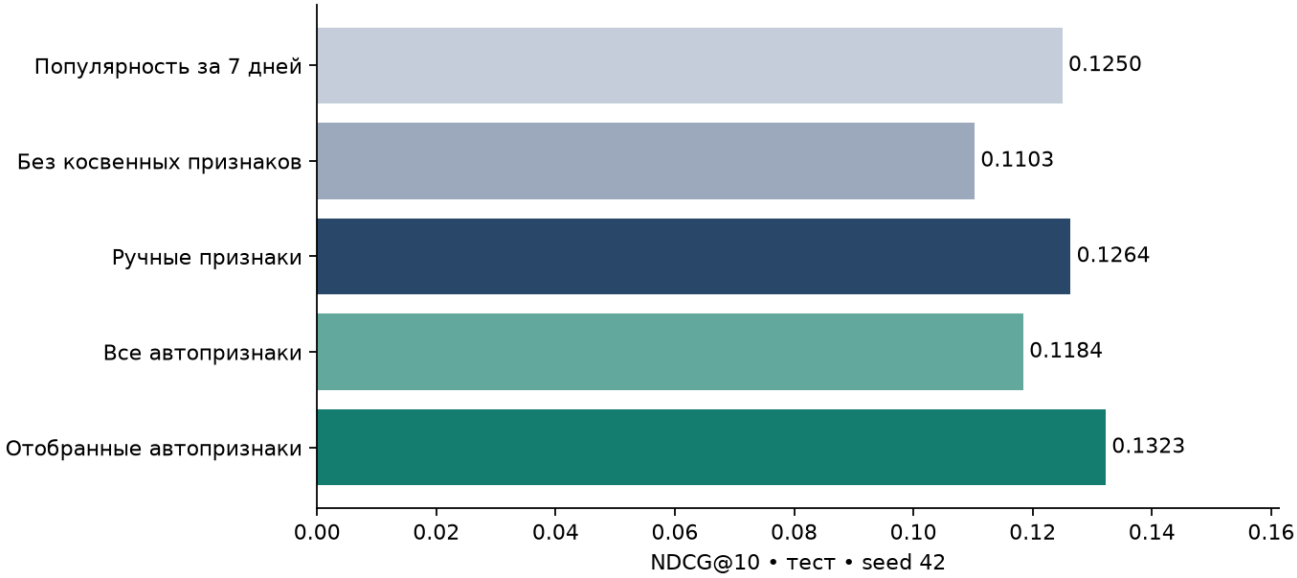
Карина Шаля · 17 октября 2026

Результат в одном абзаце

На основном seed статистически убедительное превосходство автоматического отбора не установлено: парный 95%-й интервал не лежит целиком выше нуля. NDCG@10: 0.12636 → 0.13226; разность +0.00590 (+4.67%). 95% CI: [-0.00267; +0.01532].

Знак эффекта меняется между seed: улучшение неустойчиво к случайности обучения.

10 000 пользователей; 64,636 событий; 600 000 train-пар; 64 ручных признака, 193 в полном наборе, 76 после отбора. Две validation-недели, один закрытый test, три seed основного сравнения.



Код, полный технический отчёт и все промежуточные таблицы — в сопровождающем архиве. Баллы задания и результат официального leaderboard не заявляются.

1 / Данные и временной протокол

KION: 5 476 251 строка, 962 179 пользователей, 15 706 объектов. Проверены реальные даты 13.03–22.08.2021. Использован полный data_en.zip и русские item metadata из зафиксированной версии официального репозитория.

Отдельный interactions.csv.zip оказался обрезанным (1 594 787 строк, последняя дата «20»). Он исключён. Загрузчик проверяет hash, CRC, число строк, даты и уникальность пар.

10 000 пользователей выбраны случайно среди известных до 12 июля. Сохранены все их строки. История признаков строго timestamp < t; target — новое зарегистрированное взаимодействие в [t,t+7 дней). Без показов это не CTR, а прогноз implicit feedback.

Срез	Начало	Конец	Запросы	Пары
train_1	2021-07-12	2021-07-19	2000	200000
train_2	2021-07-19	2021-07-26	2000	200000
train_3	2021-07-26	2021-08-02	2000	200000
search	2021-08-02	2021-08-09	3276	327600
tune	2021-08-09	2021-08-16	2572	257200
test	2021-08-16	2021-08-23	2377	237700

Запросы: пользователь активен в последние 28 дней. Train ограничен 2 000 запросами на срез; validation/test содержат все подходящие запросы. Будущая активность не определяет включение пользователя. Истории не усекаются.

KION агрегирован по user–item с last_watch_dt. Более ранние повторные просмотры не восстановимы. total_dur и watched_pct исключены. Корректность времени доказана относительно опубликованных псевдособытий; истинный онлайн-журнал из этих данных восстановить нельзя.

Статические item metadata считаются доступными при появлении объекта. Демография и тексты исключены. Модель обучается только на train; обновление истории событиями до test-cutoff допустимо.

2 / Кандидаты и ручной baseline

Для каждого среза известный каталог определяется только прошлой историей когорты. Просмотренные пары исключены. Четыре канала: популярность за 7 дней, популярность за всё время, item-item cosine и жанровая близость с поправкой на популярность.

Cosine вычисляется из бинарной user–item матрицы, со shrinkage co_count/(co_count+10), до 50 соседей на объект. Жанровый канал использует все жанры. Reciprocal-rank fusion sum(1/(60+rank)) оставляет 100 кандидатов. Ties детерминированы item_id.

Будущие правильные ответы не добавляются в кандидаты. Метки присоединяются после retrieval и features. Все методы используют одну сохранённую таблицу кандидатов с SHA-256-подписью.

На тесте 2377 запросов, из них 653 с будущими положительными объектами. Recall retrieval@100 = 0.3857 (macro по таким пользователям); доля целевых объектов в известном каталоге = 0.9491 (micro). Эти величины имеют разные знаменатели и не должны напрямую сравниваться как одна метрика.

Потолок NDCG@10 при идеальном ранжировании фиксированных кандидатов: 0.43154. Это диагностическая граница с известными labels, а не обученный метод.

64 признака сильного baseline

Пользователь: частоты 7/30 дней и all-time, давность, разнообразие объектов и жанров, активные дни. Объект: частоты, доли, давность, статические категории и год. Косвенные связи: user–genre/country/director/content_type, частоты, доли и давность. Также отношения 7/30, CF score, жанровый score, fusion score и rank.

Прямые user–item признаки сохранены для общей схемы, но константны в задаче новых объектов. Для агрегатов категорий берётся первое значение списка; это явное упрощение. Идентификаторы не используются как категории модели.

CatBoostClassifier, LogLoss, все 600 000 пар, без oversampling и class weights. Нулевые метки — отсутствие зарегистрированного просмотра, а не подтверждённая нерелевантность.

3 / Автоматическая генерация и отбор

Гипотеза: разные связи требуют разных масштабов времени. Ограниченная грамматика строит комбинации ключей, окон и операторов. Это автоматизация внутри заданного человеком пространства, а не универсальный SQL-агент.

Ключи: user, item, user–item и четыре косвенных связи. Дополнительные окна: 1, 3, 10, 14, 21, 60 дней. Операторы: count, сглаженная доля, отношение к 30 дням, экспоненциальное затухание с half-life 3, 10, 30 дней.

A(k,w,t) = сумма индикаторов key=k и t-w ≤ timestamp < t.
E(k,h,t) = сумма 2^(-(t-timestamp)/h) для key=k и timestamp < t.
Доля: A(u,c,w)/(A(u,w)+1).
Отношение: (A(k,w)+1)/(A(k,30)+30/w).

129 новых признаков, 193 всего. Пилотный CatBoost на train ранжирует extras по PredictionValuesChange. На validation-search сравниваются top-12/24/48 поверх всех ручных признаков. Выбран top-12, итог 76 столбцов.

Top-k	Признаков	Search NDCG@10
12	76	0.15229
24	88	0.14848
48	112	0.15197

Важность на train не использует тест, но может плохо оценивать коррелированные окна. Префиксный отбор не перебирает все подмножества. Улучшение над baseline не гарантируется.

Сравнения: manual; all-auto; selected-auto; абляция manual без косвенных признаков и retrieval scores. У абляции остаётся тот же персонализированный retrieval, поэтому она проверяет reranker, не всю персонализацию.

4 / Подбор и измерение качества

Для каждой обучаемой ветки: depth 5/7, learning_rate 0.07, l2 5, 300 деревьев; checkpoints 100/200/300 выбираются по NDCG@10 на validation-tune. Общий бюджет — два fit и шесть checkpoints на ветку. У selected есть дополнительный бюджет feature search.

Метод	F	Depth	Trees	Tune NDCG
Ручные признаки	64	5	200	0.11069
Все автопризнаки	193	5	300	0.11016
Отобранные автопризнаки	76	7	300	0.10952
Без косвенных признаков	28	7	100	0.09268

locked_config.json сохранён до построения теста, содержит время и hash протокола. Повторный запуск итоговой оценки поверх результата блокируется. Это локальный audit trail, не внешняя регистрация исследования.

Primary NDCG@10: среднее по пользователям с будущими positives. IDCG строится по всем наблюдаемым positives, включая отсутствующие в retrieval и каталоге. Recall@10 имеет тот же полный знаменатель. Запросы без positives не удаляются из данных: для них дополнительно сообщается NDCG=0 при усреднении по всем запросам.

AUC и LogLoss вычисляются на общей полной таблице кандидатов. Они условны относительно retrieval-политики и не являются метриками CTR. У popularity нет LogLoss: её score не вероятность.

Primary comparison selected − manual; парный bootstrap по пользователям, 2 000 повторов, 95% percentile CI. Дополнительные seed 17/2026 используют уже выбранные параметры и признаки, без новой настройки.

10 автоматических тестов проверяют границы времени и окон, неизменность при добавлении будущих событий, кандидатов без future leakage, полные истории, знаменатели ranking-метрик, ties и bootstrap.

5 / Итоговые результаты

Метод	F	NDCG@10	Recall@10	AUC	LogLoss
Популярность за 7 дней	2	0.12498	0.19350	0.67988	-
Без косвенных признаков	28	0.11027	0.19529	0.79192	0.01566
Ручные признаки	64	0.12636	0.19633	0.81928	0.01514
Все автопризнаки	193	0.11843	0.19663	0.81820	0.01524
Отобранные автопризнаки	76	0.13226	0.20282	0.82234	0.01520

На основном seed статистически убедительное превосходство автоматического отбора не установлено: парный 95%-й интервал не лежит целиком выше нуля.

Seed	Manual	Selected	Разность	95% CI
42	0.12636	0.13226	+0.00590	[-0.00267; +0.01532]
17	0.12649	0.11841	-0.00807	[-0.01624; +0.00013]
2026	0.12450	0.12208	-0.00242	[-0.01120; +0.00599]

Среднее NDCG@10 по трём seed: manual 0.12578 (SD 0.00111), selected 0.12425 (SD 0.00718). Это разброс обучения на одной когорте, не три независимых датасета.

Знак эффекта меняется между seed: улучшение неустойчиво к случайности обучения.

NDCG@10 по всем запросам, включая пользователей без будущего просмотра: manual 0.03471, selected 0.03633.

Все ветки показаны независимо от направления результата. Основное сравнение фиксировано до теста; тестовая таблица не используется для нового выбора метода. Интервалы условны относительно этой недели, когорты и retrieval, а не всей целевой популяции.

6 / Интерпретация результатов

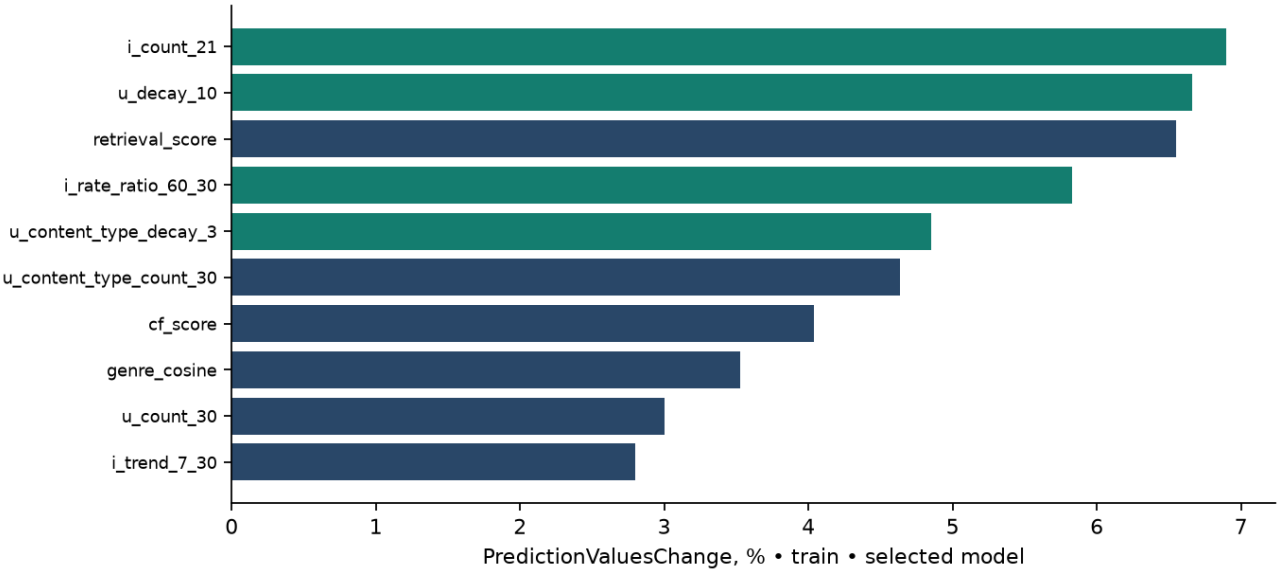
Все автопризнаки: 0.11843; без косвенных сигналов: 0.11027. LogLoss selected 0.015196, manual 0.015144: выбор по NDCG не гарантирует улучшение калибровки. Ветки имеют независимо подобранные depth/trees, поэтому эффект относится ко всей процедуре, а не только к новым столбцам.

Popularity (0.12498) близка к manual (0.12636). Сложность baseline не равна доказанному SOTA; высокая глобальная AUC может отражать прогноз активности пользователя, не лучший порядок его объектов.

Наиболее важные признаки selected-модели: i_count_21 (6.90%); u_decay_10 (6.66%); retrieval_score (6.55%); i_rate_ratio_60_30 (5.83%); u_content_type_decay_3 (4.85%); u_content_type_count_30 (4.64%); cf_score (4.04%); genre_cosine (3.53%)

Ведущие автоматически добавленные: i_count_21 (6.90%); u_decay_10 (6.66%); i_rate_ratio_60_30 (5.83%); u_content_type_decay_3 (4.85%); i_rate_ratio_1_30 (1.60%); u_country_share_21 (1.34%); i_count_3 (1.27%); i_decay_3 (1.22%); i_share_1 (0.80%); u_country_count_60 (0.66%)

Feature importance не доказывает причинный вклад отдельного окна. All-auto контролирует расширение пространства, no-indirect — совместную роль косвенных сигналов. Разрезы по длине истории сохранены в activity_strata.csv.

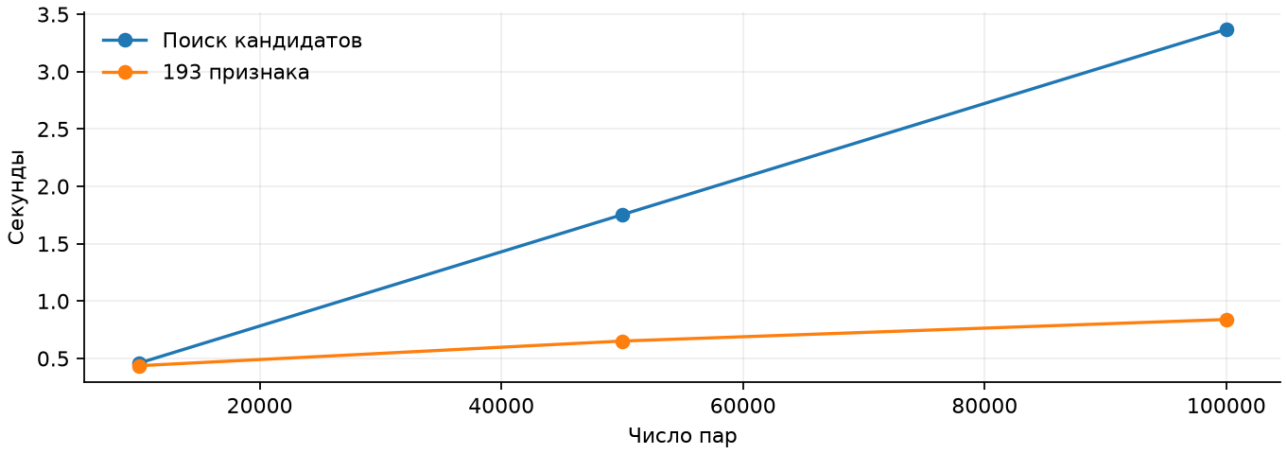


Зелёным показаны автоматически добавленные признаки, синим — ручные. Важности вычислены на обучающей выборке; тестовые метки при объяснении модели не используются.

7 / Стоимость и масштабируемость

Метод	2 fit, c	Inference, c	MiB
Ручные признаки	114.7	0.031	0.68
Все автопризнаки	147.4	0.055	0.38
Отобранные автопризнаки	120.9	0.043	1.18
Без косвенных признаков	102.7	0.024	2.16

Поиск выбранных признаков: 160.7 с сверх финального подбора. На тесте retrieval 9.15 с, все features 1.52 с; DataFrame 190.7 MiB. Inference в таблице исключает сборку Pool и чтение файлов.



Микробенчмарк меняет число запросов при фиксированной истории; один замер на размер. Он не доказывает масштабирование числа событий. 4 CPU threads, GPU не использовался. Платформа и peak RSS сохранены в JSON.

Features: примерно O(W·R·H + F·Q·C), память O(F·Q·C). Сейчас builder строит все 193 признака даже для selected; экономия feature-generation не заявляется. Для production нужны инкрементальные окна и вычисление только выбранных столбцов.

Sparse cooccurrence может уплотняться; его стоимость зависит от суммы квадратов длин историй. Top-50 pruning выполняется после умножения. Candidate retrieval сортирует каталог для каждого пользователя, примерно O(Q·I·log I). Для больших данных требуются ANN/блочные top-k и распределённые состояния.

8 / Ограничения и воспроизведение

Одна когорта и одна тестовая неделя; неизвестные показы и exposure bias; потерянные повторные сеансы; статические непроверяемые во времени metadata; неизвестные каталогу объекты; ограниченная грамматика и validation overfitting. Онлайн-эффект и перенос на Yambda не измерялись.

Следующие эксперименты: rolling-origin оценка на нескольких неделях с вложенным подбором, более крупные когорты, стабильность отбора по времени и cost-aware selection групп. Улучшение в другой метрике не заменяет заранее выбранную NDCG@10.

Запуск

Python 3.11, виртуальное окружение, pip install -r requirements-lock.txt.

```
python -m pytest -q
python -m src.data --users 10000
python -m src.experiment build-dev
python -m src.experiment select
python -m src.experiment final-test
python -m src.benchmark
python -m src.report
```

Для нового прогона сохраните results/main как results/main_reference. Сырые данные скачиваются публично, проверяются по SHA-256. Код, конфигурации, модели, логи, таблицы и per-user результаты в архиве; cache и сырые данные не включены. Полные пояснения — README.md.

Источники

Petrov et al. MTS Kion Dataset (2022)

Prokhorenkova et al. CatBoost (NeurIPS 2018)

Kanter, Veeramachaneni. Deep Feature Synthesis (2015)

Krichene, Rendle. On Sampled Metrics (KDD 2020)

Codex использован для кода, проверок и отчёта, как разрешено заданием. Все метрики рассчитаны локально. Отправка заявки и публикация репозитория не выполнялись.